

Plan What, Execute How

面向视觉-语言-动作模型的因果双层潜动作契约

Causal Dual-Latent Contracts for Vision-Language-Action Models

研究构想稿 (Research Concept Draft)

2026 年 7 月 24 日

文档定位：本文是一份可执行的研究提案，而不是已完成实验的论文。其方法假设、预期结果和新颖性判断需要通过严格对照实验验证。文中对相关工作的描述主要依据 BehaviorVLA、*From Pixels to Tokens* 的完整论文，以及 ICML 2026 论文清单中的公开摘要；对仅有摘要的工作不推断其未公开实现细节。

摘要

当前视觉-语言-动作 (Vision-Language-Action, VLA) 模型中的潜动作表示主要存在两条路线：基于视觉状态转移的 image-based latent action，用于表达“环境接下来应发生什么变化”；以及基于连续控制序列的 action-based latent action，用于表达“机器人接下来应如何运动”。已有系统研究报告，前者在长时任务与场景级泛化中更有优势，后者在高维、双臂或复杂运动协调中更有效；然而，现有方法通常分别使用二者，或将视觉与运动压缩为单一共享代码，缺少对“一个微观动作方案是否确实能够实现宏观视觉计划”的显式建模。

本文提出一个研究设想：**因果双层潜动作契约 (Causal Dual-Latent Contract)**。模型保持视觉计划 latent z^{vis} 与运动程序 latent z^{mot} 的职责分离，并学习一个动作条件结果模型，将候选运动程序映射为其预期视觉结果。推理时，系统不只生成动作，而是验证

$$F_{\psi}(o_t, z^{\text{mot}}) \approx z^{\text{vis}},$$

从而在“计划什么”与“如何执行”之间建立可检验契约。该框架可进一步支持候选动作选择、失败预警，以及对计划错误、动作选择错误和动力学偏差的结构化归因。本文给出问题定义、模型结构、训练目标、实验矩阵、关键消融、风险和最小可行实现方案。

目录

1	研究动机	3
1.1	VLA 中的两个不同问题	3
1.2	相关工作的直接启示	3
2	研究问题与核心假设	3
2.1	研究问题	3
2.2	可证伪假设	4
3	方法概览	4
3.1	视觉计划 latent	4

3.2	运动程序 latent	5
3.3	阶段状态	5
4	因果契约：从运动程序到视觉结果	5
4.1	操作性定义	5
4.2	为什么不能只做 latent 对齐	6
4.3	候选选择与拒绝机制	6
5	训练目标与训练流程	6
5.1	联合目标	6
5.2	分阶段训练	7
5.3	负样本设计	7
6	执行后错误归因与自进化扩展	7
7	与现有路线的区别	8
8	实验设计	9
8.1	核心实验矩阵	9
8.2	任务维度	9
8.3	指标	9
8.4	关键消融	9
9	预期贡献与成功标准	10
9.1	潜在贡献	10
9.2	最低成功标准	10
10	风险、反例与降级方案	11
11	最小可行实现 (MVP)	11
12	建议的研究进度	12
13	结论	12

1 研究动机

1.1 VLA 中的两个不同问题

一个机器人长时任务通常同时包含两个层次：

1. **任务空间层**：物体关系、场景状态和任务阶段应如何变化，例如“杯子最终应进入篮子”“两个碗应形成稳定堆叠”。
2. **控制空间层**：为了实现上述变化，末端位置、姿态、速度、夹爪和双臂应如何在短时间内协同。

将两者直接压入同一个动作头，会使模型同时承担语义规划、阶段追踪、运动协调和精确数值回归。一个常见失败是：模型知道最终视觉目标，却选择了无法实现该目标的局部动作；另一个失败是：局部动作短期看似合理，但长期偏离任务进度。

核心观察

视觉变化 latent 和动作序列 latent 并不是两个可互换的编码器。它们分别回答：

$$z^{\text{vis}} : \text{What should happen?} \quad z^{\text{mot}} : \text{How should the robot move?}$$

真正缺失的不是“再融合一次”，而是一个可以判断 **How** 是否实现 **What** 的显式机制。

1.2 相关工作的直接启示

From Pixels to Tokens 在统一 VLA 基线上比较了 image-based 与 action-based latent action 的多种监督方式，并报告：image-based latent action 更有利于长时推理和场景级泛化；action-based latent action 更适合复杂运动协调；直接监督 VLM 预测离散 latent token 通常优于连续 latent 回归或隐式特征对齐 [2]。

BehaviorVLA 则将行为分成固定的全局 prototype 与在线更新的 phase state，并通过 phase-conditioned decoder 约束动作生成，说明“任务结构”和“执行进度”分离对长时稳定性有价值 [1]。

与此同时，XR-1 的公开摘要提出统一视觉-运动代码，TapSampling 使用动作候选与任务进度 verifier，DUST 和 DriveWorld-VLA 强调动作与未来世界状态的联合建模。这些工作共同表明：视觉未来、动作表示和验证机制正在汇合，但“保持视觉计划与运动程序分离，并显式验证二者的结果一致性”仍是一个可独立检验的研究问题 [3, 4, 5, 6]。

2 研究问题与核心假设

2.1 研究问题

本文聚焦以下问题：

给定当前观察、语言指令和机器人状态，VLA 如何生成一个宏观视觉计划，并保证所选择的微观运动程序在当前 embodiment 和动力学条件下确实能够实现该计划？

设当前视觉观察为 o_t ，语言指令为 ℓ ，本体状态为 s_t ，机器人 embodiment 标识为 e ，历史为

$\mathcal{H}_t$ 。我们希望学习：

$$p_\theta(z_t^{\text{vis}} \mid \mathcal{H}_t, \ell), \quad \text{视觉计划分布,} \quad (1)$$

$$p_\phi(z_t^{\text{mot}} \mid \mathcal{H}_t, \ell, s_t, e, z_t^{\text{vis}}), \quad \text{运动程序分布,} \quad (2)$$

$$p_\psi(z_{t,\text{out}}^{\text{vis}} \mid o_t, s_t, e, z_t^{\text{mot}}), \quad \text{动作结果模型,} \quad (3)$$

$$p_\omega(a_{t:t+H-1} \mid o_t, s_t, z_t^{\text{vis}}, z_t^{\text{mot}}), \quad \text{连续动作解码器.} \quad (4)$$

2.2 可证伪假设

核心假设

若视觉计划 latent 与运动程序 latent 被明确分工，并通过动作结果一致性进行约束，则双 latent 模型应同时保留：

- image-based latent 在长时任务和 OOD 场景中的优势；
- action-based latent 在高维、双臂、接触型控制中的优势；
- 相比朴素拼接，更低的动作-计划失配率和更好的失败预警能力。

该假设必须通过 Pareto 式实验验证：双 latent 方法不仅平均分更高，还应分别不弱于 image-only 的长时性能和 action-only 的运动协调性能。

3 方法概览




图 1: 因果双层潜动作契约的总体结构。视觉 latent 规定期望状态变化，运动 latent 表示具体运动程序；动作结果模型验证后者是否能够产生前者。

3.1 视觉计划 latent

使用 image-based latent tokenizer 从视觉状态转移中提取监督标签：

$$c_t^{\text{vis}} = E_{\text{vis}}([o_t; o_{t+\Delta}]), \quad (5)$$

$$z_t^{\text{vis}} = Q_{\text{vis}}(c_t^{\text{vis}}), \quad (6)$$

$$\hat{o}_{t+\Delta} = D_{\text{vis}}(o_t, e(z_t^{\text{vis}})). \quad (7)$$

z^{vis} 不应被解释为自然语言 subgoal，而是从视觉状态变化中学习的离散代码。其目标是保留物体关系变化、场景进度和任务相关动态，同时尽量忽略光照、相机抖动和无关背景变化。第一版可直接复用已有 image-based latent action 训练方式，并冻结 tokenizer，以隔离后续方法增益来源。

3.2 运动程序 latent

使用 action-based tokenizer 将长度为 H 的连续动作块编码为离散运动程序：

$$c_t^{\text{mot}} = E_{\text{mot}}(a_{t:t+H-1}), \quad (8)$$

$$z_t^{\text{mot}} = Q_{\text{mot}}(c_t^{\text{mot}}), \quad (9)$$

$$\hat{a}_{t:t+H-1} = D_{\text{mot}}(e(z_t^{\text{mot}})). \quad (10)$$

z^{mot} 不是“抓取”“向左”等文字，而是一个由动作重建目标自动形成的离散代码序列。它应重点编码多自由度耦合、速度变化、姿态旋转、夹爪时序和双臂同步关系。

3.3 阶段状态

同一个视觉计划可能在不同阶段对应不同动作。例如“杯子进入篮子”可以处于尚未抓取、运输中、目标上方或释放阶段。因此执行器可额外条件化于在线阶段表示：

$$z_t^{\text{phase}} = G_{\rho}(\mathcal{H}_t, s_t),$$

其中 G_{ρ} 可采用因果 Transformer、Mamba 或轻量 recurrent encoder。与 BehaviorVLA 不同，第一版不需要引入 prototype Memory Bank；阶段表示只用于消除动作条件歧义。

4 因果契约：从运动程序到视觉结果

4.1 操作性定义

训练一个动作条件结果模型：

$$\widehat{z_{t,\text{out}}^{\text{vis}}} = F_{\psi}(o_t, s_t, e, z_t^{\text{mot}}),$$

其目标是预测执行 z_t^{mot} 后会出现的视觉变化 latent。给定规划器输出 z_t^{vis} ，定义契约误差：

$$\mathcal{E}_{\text{contract}}(z_t^{\text{vis}}, z_t^{\text{mot}}) = d(F_{\psi}(o_t, s_t, e, z_t^{\text{mot}}), z_t^{\text{vis}}).$$

$d(\cdot, \cdot)$ 可使用 token 交叉熵、codebook embedding 距离或校准后的负对数似然。

关于“因果”一词的边界

这里的“因果契约”是一个操作性名称：动作方案在当前状态下应导致与计划一致的结果。除非引入可识别的干预数据、充分覆盖的行为策略和额外结构假设，否则本文不声称恢复完整结构因果模型。更严格的表述是“动作条件结果一致性契约”。

4.2 为什么不能只做 latent 对齐

强制 $z^{\text{vis}} = z^{\text{mot}}$ 或将二者映射到一个共享 codebook, 会隐含一对一关系; 但同一个视觉目标往往具有多个有效动作实现:

$$z^{\text{vis}} \longrightarrow \{z_1^{\text{mot}}, z_2^{\text{mot}}, \dots\}.$$

这种一对多关系取决于机器人形态、初始姿态、控制频率、可达性和局部障碍。因此, 更合理的是学习条件分布:

$$p_\phi(z^{\text{mot}} \mid z^{\text{vis}}, o_t, s_t, e, z_t^{\text{phase}}),$$

再通过契约模型判断某个候选是否在当前条件下可执行。

4.3 候选选择与拒绝机制

推理时, 从运动程序分布采样 K 个候选:

$$z_{t,1}^{\text{mot}}, \dots, z_{t,K}^{\text{mot}} \sim p_\phi(z^{\text{mot}} \mid z_t^{\text{vis}}, \cdot).$$

选择分数可定义为:

$$S_k = -\mathcal{E}_{\text{contract}}(z_t^{\text{vis}}, z_{t,k}^{\text{mot}}) + \alpha \log p_\phi(z_{t,k}^{\text{mot}} \mid \cdot) - \beta C_{\text{dyn}}(z_{t,k}^{\text{mot}}),$$

其中 C_{dyn} 是可选的动力学、碰撞或平滑性代价。最终选择:

$$k^* = \arg \max_k S_k.$$

若所有候选均满足

$$\min_k \mathcal{E}_{\text{contract}}(z_t^{\text{vis}}, z_{t,k}^{\text{mot}}) > \tau,$$

则模型应拒绝直接执行, 并触发重新采样、重新规划或外部高层 Agent。这样, Agent 不是核心方法, 而是异常处理的上层调用者。

5 训练目标与训练流程

5.1 联合目标

一个基础版本可使用:

$$\mathcal{L} = \mathcal{L}_{\text{action}} + \lambda_v \mathcal{L}_{\text{vis}} + \lambda_m \mathcal{L}_{\text{mot}} + \lambda_c \mathcal{L}_{\text{contract}} + \lambda_p \mathcal{L}_{\text{phase}} + \lambda_{\text{cal}} \mathcal{L}_{\text{cal}}. \quad (11)$$

各项定义如下:

$$\mathcal{L}_{\text{action}} = \|\hat{a}_{t:t+H-1} - a_{t:t+H-1}^*\|_2^2, \quad (12)$$

$$\mathcal{L}_{\text{vis}} = \text{CE}(p_\theta(z_t^{\text{vis}} \mid \mathcal{H}_t, \ell), z_t^{\text{vis}}), \quad (13)$$

$$\mathcal{L}_{\text{mot}} = \text{CE}(p_\phi(z_t^{\text{mot}} \mid z_t^{\text{vis}}, \cdot), z_t^{\text{mot}}), \quad (14)$$

$$\mathcal{L}_{\text{contract}} = \text{CE}(p_\psi(z_{t,\text{out}}^{\text{vis}} \mid o_t, s_t, e, z_t^{\text{mot}}), z_t^{\text{vis}}). \quad (15)$$

$\mathcal{L}_{\text{cal}}$ 用于校准契约误差与真实成功/失败的关系；可以采用 Brier loss、temperature scaling 或 pairwise ranking。 $\mathcal{L}_{\text{phase}}$ 可使用时间顺序、相对进度或未来可预测性约束，而不只要求不同时间点互相分离。

5.2 分阶段训练

1. **Stage A: 训练并冻结两个 tokenizer**。分别在图像转移和动作块上训练 VQ 模型。第一版不联合更新，避免 representation drift 混淆实验结论。
2. **Stage B: 训练双 latent VLA**。使用离散 token 交叉熵监督视觉计划器和运动程序生成器，同时保留连续动作头。
3. **Stage C: 训练契约模型**。使用 $(o_t, s_t, z_t^{\text{mot}}, z_t^{\text{vis}})$ 监督动作结果预测，并通过负样本构造提高区分性。
4. **Stage D: 联合微调与校准**。在稳定后小学习率联合微调，训练候选排序、拒绝阈值和错误检测。
5. **Stage E (可选): 部署经验自进化**。利用真实执行结果形成细粒度错误归因，再选择性更新对应模块。

5.3 负样本设计

契约模型不能只见到正确动作，否则可能退化为任务类别识别器。需要构造具有诊断性的负样本：

- 同任务但错误阶段的 z_t^{mot} ；
- 相同场景中其他任务的 z_t^{mot} ；
- 保持位移但打乱夹爪或旋转时序的 z_t^{mot} ；
- 左右臂交换、速度缩放、时间反转等结构扰动；
- 来自策略 rollout 的真实失败动作。

重点是区分“动作看起来常见”与“动作能够实现当前计划”。

6 执行后错误归因与自进化扩展

执行后得到真实未来观察 $o_{t+\Delta}^{\text{obs}}$ ，编码为：

$$z_{t,\text{obs}}^{\text{vis}} = Q_{\text{vis}} E_{\text{vis}}([o_t; o_{t+\Delta}^{\text{obs}}]).$$

系统中存在三个视觉 latent：

- $z_{t,\text{plan}}^{\text{vis}}$ ：规划器希望发生的变化；
- $z_{t,\text{pred}}^{\text{vis}}$ ：契约模型预测动作会造成的变化；
- $z_{t,\text{obs}}^{\text{vis}}$ ：真实世界实际发生的变化。

可据此进行初步错误归因：

表 1: 基于三种视觉 latent 的结构化错误归因。

错误类型	判据（示意）	优先更新模块
动作选择错误	$d(z_{\text{pred}}^{\text{vis}}, z_{\text{plan}}^{\text{vis}})$ 大	运动程序生成器、候选排序器
动力学/执行偏差	预测与计划接近，但 $d(z_{\text{obs}}^{\text{vis}}, z_{\text{pred}}^{\text{vis}})$ 大	结果模型、embodiment adapter、底层控制
视觉计划错误	动作实现计划，但任务进度或回报未提升	视觉计划器、高层任务分解
阶段估计错误	同一计划下持续选择不匹配当前阶段的动作	phase estimator
感知错误	视觉 latent 在轻微视角/遮挡变化下剧烈跳变	视觉 tokenizer、观测编码器

这比只使用 episode-level 成功/失败标签提供更细的 credit assignment。不过，自动归因必须通过人工标注子集或受控故障注入进行验证，不能仅凭 latent 距离自证正确。

7 与现有路线的区别

表 2: 本构想与代表性路线的定位比较。

路线	表示设计	主要机制	与本文区别
BehaviorVLA[1]	全局 prototype + 在线 phase	检索任务先验并按阶段解码	不显式区分视觉计划与运动程序，也不验证动作会产生何种视觉结果
From Pixels to Tokens[2]	image LA 或 action LA	统一基线下比较监督策略	主要分别评估两类 latent；本文研究二者之间的条件结果契约
XR-1[3]	统一视觉-运动 code	双分支 VQ 对齐共享离散空间	本文保留两个空间，建模一对多映射而非强制统一 code
TapSampling[4]	Action-VAE latent	多候选采样 + 任务进度 verifier	本文 verifier 的目标是动作结果与显式视觉计划的一致性，并用于错误分层
DUST / DriveWorld-VLA[5, 6]	世界状态与动作 latent	联合未来建模或动作条件想象	本文聚焦紧凑离散计划-执行契约，而非完整视觉生成或驾驶世界模型
本文	分离 z^{vis} 与 z^{mot}	动作条件结果预测、候选验证、错误归因	核心问题是“该动作方案能否实现该视觉计划”

明确不做什么

- 不把两个 latent loss 简单相加后称为主要贡献；
- 不把视觉和动作强行压入同一 codebook；
- 不依赖昂贵像素级未来视频作为唯一 verifier；
- 不把 Memory Bank、Agent、RL、世界模型和采样算法全部堆进第一版；
- 不将 latent 距离直接宣称为真实因果关系或安全证明。

8 实验设计

8.1 核心实验矩阵

最基本的 2×2 对照如下：

表 3: 证明互补性所需的最小模型矩阵。

模型	Visual LA	Motor LA	Contract
Baseline	—	—	—
Image-only	✓	—	—
Action-only	—	✓	—
Naive dual latent	✓	✓	—
Shared-code alignment	✓	✓	隐式
Proposed	✓	✓	显式

必须匹配 backbone、数据、训练步数、action head、placeholder 数量和推理预算。特别要加入 token-length matched baseline，以排除更多 placeholder 或计算量造成的增益。

8.2 任务维度

建议至少覆盖三类任务：

1. **长时、场景导向**：LIBERO-Long、CALVIN 长链或等价多阶段任务，验证视觉计划连续性。
2. **高维、运动复杂**：RoboTwin 双臂协调、接触密集或高频控制任务，验证运动程序 latent。
3. **真实环境 OOD**：对象位置、背景、照明、容器形状和障碍变化，验证场景泛化与契约拒绝。

更强的版本需要至少两个 embodiment：共享视觉计划 tokenizer，而运动 tokenizer 或 adapter 可按机器人特化。这能直接检验“计划共享、执行特化”的结构是否合理。

8.3 指标

除成功率外，需要报告：

- 长时任务完成长度、阶段跳跃率和执行漂移；
- 双臂同步误差、夹爪时序误差、动作平滑性和接触失败率；
- 契约误差对失败的 AUROC、AUPRC、Brier score 和校准曲线；
- 候选选择命中率、拒绝率、错误拒绝率和额外延迟；
- OOD 场景中 image-only、action-only 与 proposed 的 Pareto 对比；
- 错误归因准确率：计划、动作、动力学和阶段故障能否被正确区分。

8.4 关键消融

1. 并行双监督 vs. 层级条件化 $z^{\text{vis}} \rightarrow z^{\text{mot}}$ ；

2. 显式契约 vs. 朴素 concat vs. shared-code alignment;
3. 离散 token vs. 连续 latent;
4. 无 phase、简单时间编码、因果 phase encoder;
5. 单候选 vs. 多候选; 相同推理 FLOPs 下的公平对比;
6. 契约模型只看 z^{mot} vs. 同时看当前观察、本体状态与 embodiment;
7. 正确轨迹训练 vs. 加入结构负样本和真实失败 rollout;
8. 冻结 tokenizer vs. 联合微调 tokenizer。

9 预期贡献与成功标准

9.1 潜在贡献

若实验支持假设，论文可形成以下贡献：

1. **问题层贡献**：将 latent action 的设计问题从“视觉或动作二选一”重述为“计划 latent 与执行 latent 的结果一致性”。
2. **方法层贡献**：提出分离视觉计划和运动程序的一对多层级生成，以及可训练的动作结果契约。
3. **推理层贡献**：使用契约分数进行候选选择、拒绝和按需重规划，而非无条件执行单次动作。
4. **诊断层贡献**：利用 plan-predicted-observed 三元组进行计划、动作和动力学错误归因。
5. **经验层贡献**：展示双 latent 在长时任务和复杂运动间取得 Pareto improvement，而不是只提高总体平均分。

9.2 最低成功标准

项目不应以“平均成功率提升 1-2 个点”作为唯一成功判据。更可信的最低标准是：

- 在长时任务上不低于最强 image-only 模型；
- 在复杂运动任务上不低于最强 action-only 模型；
- 明显优于 naive dual latent，证明增益来自契约而不是多任务监督；
- 契约误差对真实失败具有可校准预测力；
- 在相同推理预算下，候选验证收益仍成立；
- 至少一种受控故障中，错误归因显著优于随机或单一 success critic。

10 风险、反例与降级方案

风险 1：两种 latent 的语义并不互补

视觉 tokenizer 可能编码大量无关外观变化，动作 tokenizer 可能只记住机器人 ID。应通过 mutual information、跨视角一致性、任务条件检索和受控扰动分析检查 latent 内容。若互补性不足，先改 tokenizer，而不是继续堆叠 VLA 模块。

风险 2：契约模型学到数据集捷径

F_ψ 可能只通过场景或任务 ID 猜测视觉计划，而忽略 z^{mot} 。必须使用动作交换、阶段打乱、同场景反事实动作和 gradient attribution 验证其确实依赖运动 latent。

风险 3：多候选推理过慢

第一版应同时报告单候选训练正则化版本和 K 候选版本。若实时性不足，可蒸馏 contract-aware ranking 到单次 action head，或只在不确定度高时触发候选验证。

风险 4：视觉计划过粗，无法约束精细接触

可采用多尺度 z^{vis} ：较长时间尺度描述任务状态变化，较短时间尺度描述接触前局部视觉几何。但需避免直接复制完整 coarse-to-fine action hierarchy；核心仍是动作结果可验证性。

风险 5：同一视觉结果对应多种动作，监督出现多模态冲突

执行器必须建模分布而非确定回归。可使用 autoregressive token、latent flow 或离散 diffusion；不建议用简单 MSE 把多种动作平均成不可执行轨迹。

11 最小可行实现 (MVP)

为了尽快判断 idea 是否成立，第一版应严格减法：

1. 选择一个公开 VLA baseline，固定视觉语言 backbone 和连续 action head；
2. 在 LIBERO 上训练一个 image tokenizer 和一个 action tokenizer；
3. 增加两个离散 token head，先完成 Image-only、Action-only 和 Naive dual 三组对照；
4. 训练一个小型 contract predictor，输入当前视觉特征与 action token，输出 image token；
5. 仅采样 $K = 4$ 个动作候选，比较 contract ranking 与概率最大候选；
6. 先做 LIBERO-Long，再转向 RoboTwin 双臂任务；
7. 只有当 controlled study 显示互补和契约收益后，再加入 phase、跨 embodiment 和自进化。

建议的首篇论文边界

第一篇论文只需要证明：分离视觉计划与运动程序，并显式验证动作结果，比单类 latent、朴素双 latent 和共享 code 更稳定地覆盖长时规划与复杂控制。自进化、外部 Agent 和 Schrödinger Bridge 均可作为后续扩展，而不应阻塞核心实验。

12 建议的研究进度

表 4: 一个紧凑的十二周验证计划。

时间	主要工作
第 1-2 周	复现统一 VLA baseline, 建立固定数据、训练和评测流水线
第 3-4 周	训练/验证 image tokenizer 与 action tokenizer, 做 code 使用率和重建分析
第 5 周	完成 Image-only、Action-only、Naive dual 三组受控实验
第 6-7 周	实现 contract predictor、结构负样本和单候选一致性训练
第 8 周	加入多候选排序与拒绝阈值, 完成校准评测
第 9-10 周	LIBERO-Long 与 RoboTwin 互补性、Pareto 和消融实验
第 11 周	OOD、故障注入、错误归因; 条件允许时做第二 embodiment 或真机
第 12 周	汇总失败案例、统计显著性、图表和论文初稿

13 结论

本文构想的重点不是把 image latent 和 action latent 简单拼接, 而是建立以下可检验链条:

视觉计划: 应该发生什么 → 运动程序: 如何实现 → 结果契约: 是否真的实现

如果该链条成立, 它可以解释为什么两类 latent 在不同任务上各有所长, 并给出一个统一但不混同的架构: 视觉计划可以跨场景、任务甚至 embodiment 共享, 运动程序则根据机器人状态和动力学特化; 契约模型负责连接二者, 并在执行前提供验证, 在执行后提供错误归因。

该方向具有成为强方法论文的潜力, 但新颖性不来自“双 latent”本身, 而来自: **一对多的计划-执行关系、动作条件结果预测、契约式选择与可验证错误分层**。最优先的工作是完成严格受控的最小实验, 证明它确实同时保留两类 latent 的优势。

参考文献

- [1] B. Hu, Z. Li, R. Shao, et al. From Abstraction to Instantiation: Learning Behavioral Representation for Vision-Language-Action Model. *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, 2026. arXiv:2605.22671.
- [2] Y. Lin, H. Li, Y. Li, et al. From Pixels to Tokens: A Systematic Study of Latent Action Supervision for Vision-Language-Action Models. *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, 2026. arXiv:2605.04678.
- [3] S. Fan, K. Wu, Z. Che, et al. XR-1: Towards Versatile Vision-Language-Action Models via Learning Unified Vision-Motion Representations. *ICML*, 2026. Bibliographic description based on the public conference abstract.
- [4] S. Zhao, S. Zhang, S. Yang, et al. TapSampling: Inference-Time Sampling with a Task-Progress-Understanding Verifier for Robotic Manipulation. *ICML*, 2026. Bibliographic description based on the public conference abstract.
- [5] J. Won, K. Lee, H. Jang, D. Kim, and J. Shin. Dual-Stream Diffusion for World-Model Augmented Vision-Language-Action Model. *ICML*, 2026. Bibliographic description based on the public conference abstract.
- [6] F. Jia, L. Liu, Z. Song, et al. DriveWorld-VLA: Unified Latent-Space World Modeling with Vision-Language-Action for Autonomous Driving. *ICML*, 2026. Bibliographic description based on the public conference abstract.
- [7] W. Li, X. Su, D. Niu, et al. Sentinel-VLA: A Metacognitive VLA Model with Active Status Monitoring for Dynamic Reasoning and Error Recovery. *ICML*, 2026. Bibliographic description based on the public conference abstract.
- [8] K. Black, N. Brown, J. Darpinian, et al. $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization. arXiv:2504.16054, 2025.
- [9] Q. Bu, Y. Yang, J. Cai, et al. UniVLA: Learning to Act Anywhere with Task-Centric Latent Actions. arXiv:2505.06111, 2025.
- [10] S. Lee, Y. Wang, H. Etukuru, H. J. Kim, N. M. M. Shafiullah, and L. Pinto. Behavior Generation with Latent Actions. arXiv:2403.03181, 2024.